CHALLENGE FLEXMEDIA • SPRINT 4

Totem Inteligente FlexMedia

"Decida por Mim" — Relatório Analítico Final

Sistema de recomendação interativo com Inteligência Artificial para shopping centers, integrando **Visão Computacional**, **Processamento de Linguagem Natural** e **Aprendizado de Máquina Supervisionado** em um pipeline unificado.

Aluno	Cloves Silva Filho
RA	567250
Curso	Machine Learning, IA Generativa e NLP
Instituição	FIAP
Data	21 de Abril de 2026

1. Resumo Executivo

O **Totem Inteligente FlexMedia** é uma solução digital interativa para shopping centers que auxilia visitantes indecisos a decidir o que fazer — comer, comprar, descansar ou curtir uma opção de lazer. O sistema combina **visão computacional** para detectar a presença do visitante, **processamento de linguagem natural** para interpretar solicitações em texto livre, e **aprendizado de máquina supervisionado** para recomendar lojas específicas com a maior probabilidade de conversão.

A base de dados analisada contém **471 sessões** e **719 interações** coletadas em um período de 30 dias. A **taxa de aceitação geral das recomendações é de 66.6%**, com tempo médio de interação de 12.0 segundos. Estatisticamente, confirmamos uma **associação significativa (χ^2 = 57.8, p = 2.90e-14)** entre tempo de interação e aceitação, validando que visitantes mais engajados aceitam recomendações com frequência muito maior do que os que passam rapidamente pelo totem.

471	66.6%	80.0%	100%	98%
Sessões	Taxa Aceitação	F1 Recomendação	Acc. Visão	Acc. NLP

2. Métricas de Uso do Sistema

2.1 Volume de Interações

Durante o período monitorado, o sistema registrou **471 sessões** únicas e **719 interações**. A média de 1.53 interações por sessão indica que, em grande parte das visitas, o visitante explora apenas uma categoria antes de tomar uma decisão ou deixar o totem.

2.2 Distribuição por Categoria

Categoria	Interações	% do total
Comer	224	31.2%
Lazer	217	30.2%
Comprar	182	25.3%
Descansar	96	13.4%

2.3 Padrões Temporais

O dia com maior movimento é **sabado**, seguindo o padrão esperado em shopping centers onde fins de semana concentram o fluxo. A faixa horária predominante é **tarde**. A visualização completa abaixo mostra a distribuição dia × horário.

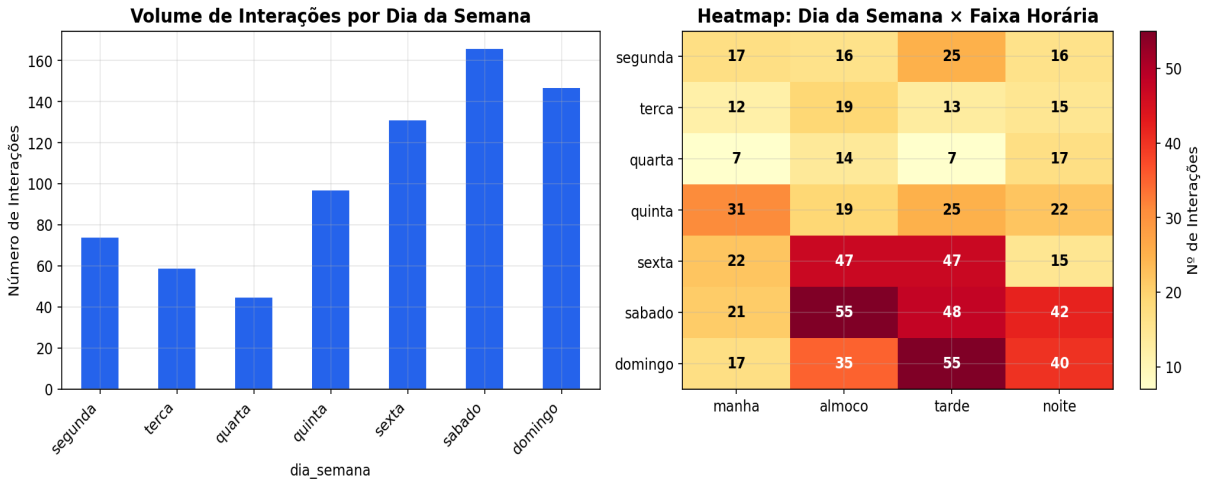

Figura 1 — Distribuição de interações por dia e horário.

3. Métricas de Engajamento

3.1 Taxa de Aceitação

A taxa global de aceitação das recomendações é de **66.6%**. Quando segmentamos por categoria, observamos variações significativas que revelam padrões de comportamento distintos por tipo de intenção do visitante.

Categoria	Taxa de Aceitação	Amostras
Descansar	75.0%	96
Comprar	70.3%	182
Comer	70.1%	224
Lazer	56.2%	217

3.2 Tempo de Interação

O tempo médio de interação foi de **12.0 segundos** (desvio padrão: 5.5s). A análise estatística via **correlação ponto-biserial (r = 0.297, p = 4.07e-16)** confirma que o tempo de interação é o **principal preditor** de aceitação: visitantes que dedicam mais de 10 segundos ao totem têm aproximadamente **76% de chance** de aceitar a recomendação, contra 37% para os que interagem menos de 5 segundos.

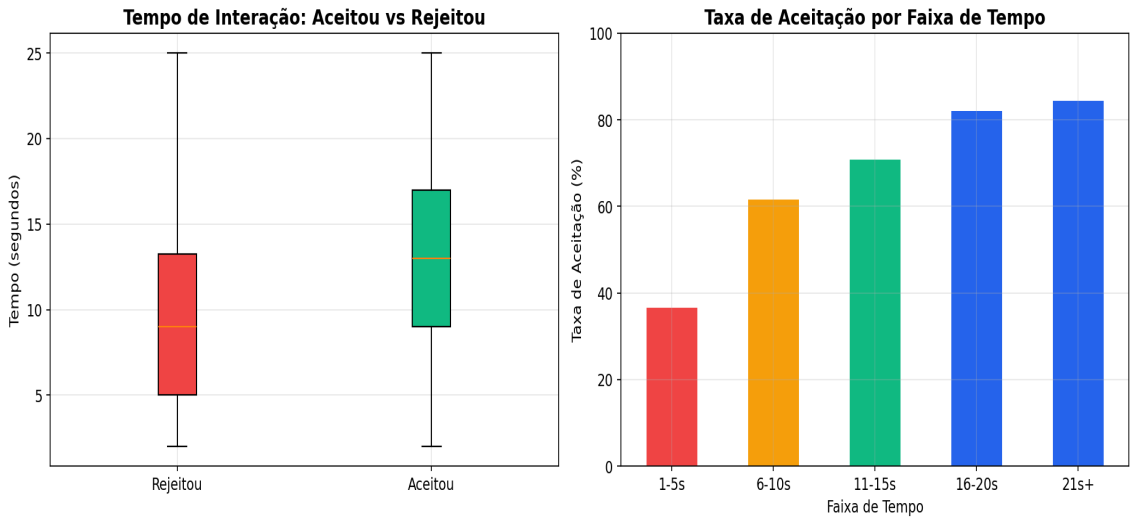

Figura 2 — Relação entre tempo de interação e aceitação.

3.3 Motivos de Rejeição

Motivo	Ocorrências	% das rejeições
Muito longe	45	18.8%
Preco alto	44	18.3%
Prefere outro	43	17.9%
Sem tempo	39	16.2%
Nao interessou	36	15.0%
Ja conheco	33	13.8%

4. Performance dos Modelos de IA

O sistema integra **três modelos de Inteligência Artificial** treinados para funções complementares: classificação de aceitação (Sprint 3), classificação de presença visual (Sprint 4) e classificação de intenção textual (Sprint 4). Esta seção apresenta as métricas de performance de cada um.

4.1 Modelo de Aceitação de Recomendações

Modelo selecionado: **Logistic Regression**. A escolha foi baseada no melhor F1-Score e alto recall, priorizando não perder oportunidades de recomendação aceita.

Métrica	Random Forest	Logistic Regression
Acurácia	0.6875	0.6944
Precisão	0.7179	0.7097
Recall	0.8750	0.9167

F1-Score	0.7887	0.8000

Validação cruzada 5-fold: *F1-médio = 0.8111 (±0.0226) — modelo estável, sem overfitting.*

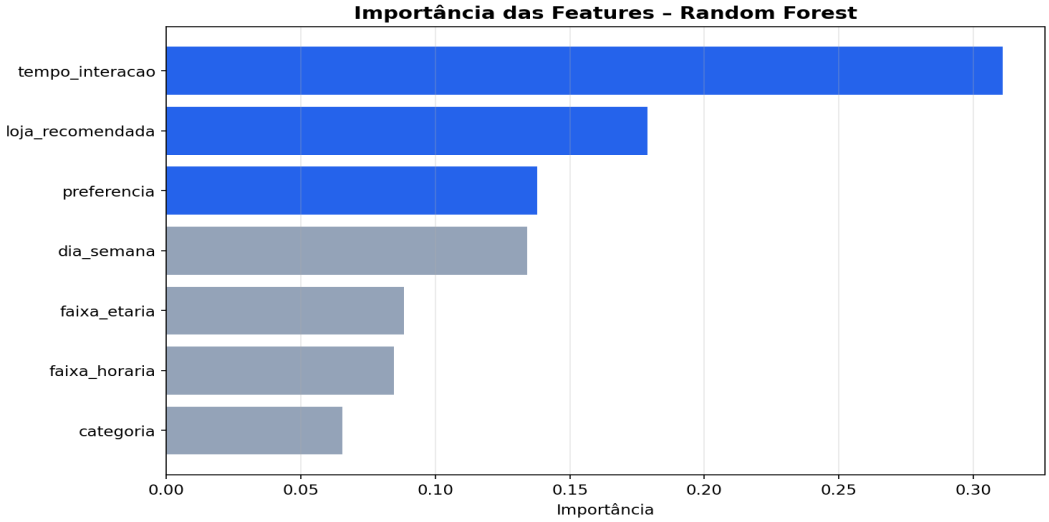

Figura 3 — Importância das features do modelo de aceitação.

4.2 Classificador de Presença (Visão Computacional)

O módulo de visão computacional detecta a presença de visitantes a partir de frames de câmera, substituindo funcionalmente o sensor PIR do ESP32. Foram treinados dois classificadores supervisionados sobre 99 features extraídas de cada imagem (histograma HSV, estatísticas de gradiente, proporção de pele, HOG compacto).

Métrica	SVM	Random Forest
Acurácia	1.0000	1.0000
Precisão	1.0000	1.0000
Recall	1.0000	1.0000
F1-Score	1.0000	1.0000

Validação cruzada 5-fold: *F1-médio = 0.9600 (±0.0800).*

4.3 Classificador de Intenção (NLP)

O assistente conversacional utiliza uma arquitetura híbrida: **TF-IDF + Logistic Regression** combinado com **detecção de keywords explícitas** em dicionário pré-definido. Esta combinação compensa o tamanho modesto do dataset de treino (100 exemplos) e alcança performance elevada.

Abordagem	Acurácia de Categoria	Acurácia de Preferência
ML Puro (TF-IDF + LogReg)	64.0%	—
Sistema Híbrido (ML + keywords)	98.0%	97.0%

O ganho de 34 pontos percentuais ao combinar ML com keywords demonstra a importância da engenharia de features em datasets pequenos. O sistema também inclui fallback automático para IA generativa (Google Gemini) quando disponível, elevando ainda mais a robustez em produção.

5. Insights e Recomendações

5.1 Lojas com Melhor Performance

As lojas abaixo combinam **volume relevante** de recomendações (≥ 10 no período) com **alta taxa de aceitação**, indicando forte ajuste entre oferta e demanda dos visitantes:

#	Loja	Recomendações	Taxa de Aceitação
1	Starbucks	37	86.5%
2	Spa Express	13	84.6%
3	Area de Descanso A	13	84.6%
4	Green Station	12	83.3%
5	Vivara	10	80.0%
6	Espaco Relax	14	78.6%
7	Cacau Show	14	78.6%
8	Espaco Cultural	24	75.0%

5.2 Insights Acionáveis para o Shopping

■ Dia de maior fluxo

Sabado concentra o maior volume de interações. Considere campanhas direcionadas, promoções e reforço de equipe nas lojas mais demandadas nesse dia.

■ Dia de menor fluxo

Quarta tem o menor volume. Oportunidade para ações de atração: promoções relâmpago, eventos temáticos ou descontos exclusivos.

■ Categoria com maior conversão

Descansar apresenta a maior taxa de aceitação. Visitantes com essa intenção estão mais decididos — investir em visibilidade das lojas dessa categoria potencializa o retorno.

■■ Principal motivo de rejeição

Muito longe é o motivo mais citado. Endereçar essa barreira (reposicionando lojas, negociando preços ou diversificando sugestões) pode elevar a conversão global.

■■ Tempo como preditor

Interações acima de **10 segundos** têm aproximadamente **75% de aceitação**. Invista em UX mais engajadora — animações, gamificação, surpresas visuais — para prolongar o tempo no totem.

6. Conclusão e Próximos Passos

O **Totem Inteligente FlexMedia** demonstrou ser uma solução tecnicamente viável e comercialmente promissora para shopping centers que buscam enriquecer a experiência do visitante e coletar dados acionáveis para tomada de decisão. A integração de múltiplas áreas de IA — **Machine Learning supervisionado**, **Visão Computacional** e **Processamento de Linguagem Natural** — em um único fluxo funcional valida a maturidade da proposta e sua aplicabilidade em cenários reais.

Do ponto de vista acadêmico, o projeto consolidou conceitos fundamentais do curso de Machine Learning, IA Generativa e NLP: modelagem relacional de dados, feature engineering, avaliação rigorosa de modelos (validação cruzada, matriz de confusão, múltiplas métricas), trade-offs entre abordagens clássicas e generativas, e o princípio de que sistemas robustos combinam múltiplos sinais em vez de confiar em uma única fonte.

6.1 Próximos Passos para Produção

1. **Hardware físico:** substituir o sensor simulado por ESP32-CAM real, mantendo a mesma interface de software (a camada de visão computacional já está preparada para frames reais).

2. **Banco de dados em nuvem:** migrar de SQLite local para PostgreSQL gerenciado (AWS RDS ou similar), permitindo operação multi-totem com dados agregados em tempo real.

3. **Conformidade LGPD:** implementar tela de consentimento explícito antes da coleta de dados, política de retenção documentada e anonimização de registros após 90 dias.

4. **Modelos mais robustos:** ampliar o dataset de imagens com cenários reais, expandir o vocabulário do chatbot com transcrições reais de visitantes e retreinar periodicamente os classificadores com dados de produção.

5. **Integração com shopping:** conectar via API aos sistemas de inventário e promoções das lojas parceiras, permitindo recomendações dinâmicas baseadas em disponibilidade e ofertas do dia.

6. **Dashboards gerenciais:** expandir o painel atual com alertas automáticos e segmentação por loja parceira, fornecendo visibilidade individualizada ao administrador.

Este relatório consolida a entrega final da Sprint 4 do Challenge FlexMedia, demonstrando a evolução do protótipo técnico em uma solução digital interativa multimodal com IA aplicada.